Web 第二次实验实验报告

目录

简介

小组成员

ID	Name
PB21030794	王道宇(team leader)
PB21030802	吴泽众(team members)
PB21030814	王昱(team members)

实验环境

> System: Win 11 / Linux server
>
> IDE / Editor: Pycharm , Visual Studio Code
>
> Language: python3 , Jupyter Notebook
>
> Environment / tool: Anaconda , git

> Repository: WebInfo (private now)

实验内容简介

Stage1

1. 从公开图谱中匹配已经从 Freebase 中抽取的 578 部电影实体有关系的实体和关系，并生成图谱。
2. 按照规则对抽取到的图谱进行处理，过滤出数量在合适区间的实体或关系。

Stage2

1. 根据映射关系，将Stage1得到的图谱映射为由索引值组成的三元组
2. 将图谱嵌入到原来的model当中
3. 选择评测指标比较图谱嵌入后的model与图谱嵌入前的model的性能

实现过程介绍

Stage1

关于 Freebase 数据库

Freebase是一个已经不再活跃的结构化知识数据库，它由Meta公司创建，于2016年关闭。Freebase旨在建立一个包含大量实体及其之间关系的知识图谱，以支持广泛的信息检索、语义搜索和知识图谱构建。

关于Freebase数据库：

1. **数据结构：** Freebase采用图谱结构，将知识组织成实体和关系的网络。实体包括人物、地点、电影、书籍等，而关系描述了这些实体之间的连接。
2. **三元组格式：** Freebase的数据以三元组（主体-谓词-客体）的格式存储。例如，一个关于电影的三元组可能是（Inception，genre，Science Fiction）。

提取三元组并计数

在第一阶段中，我们需要从给定的 578 个电影实体出发，将其作为头或尾与 Freebase 中的三元组匹配。

提取的代码如下：

```
1  def ExtractFreebase(freebase_path, KG_path, entities_set):
2      with gzip.open(freebase_path, 'rb') as f:
3          with open(KG_path, 'w', encoding='utf-8') as f_out:
4              for line in f:
5                  line = line.strip()
6                  triplet = line.decode().split('\t')[:3]
7                  if triplet[0] in entities_set or triplet[2] in                    entities_set:
8                      f_out.write('\t'.join(triplet) + '\n')
```

过滤三元组

在实体和关系的筛选中，我们有三重过滤标准：

1. 只保留具有 `<http://rdf.freebase.com/ns/` 前缀的实体。因为存在一类关系 http://rdf.freebase.com/ns/common.notable_for.display_name，这类关系的构成三元组的尾实体通常为一种语言的字符串，而此类关系的尾实体一般不会和其他的实体相连。便于缩小子图规模
2. 只抽取在子图中出现数目在一定范围内的实体：如果某个实体数目太少，就会导致它与其他实体关系过少，进而导致它的语义关系不强。如果某个实体数量过多，就会导致它形成一种过中心化的趋势，进而导致其呈现“大 V”化。关系也同理，但是考虑到关系一般不会太多，所以没有给关系做上界划分。

过滤的代码如下（以实体过滤为例）：

```
def __filter_entities(self):
        triple_list_filter_entities = []
        for triplet in self.triple_list:
            if (self.entities_min <= self.entities_count[triplet[0]] <= self.entities_max) and (
                    self.entities_min <= self.entities_count[triplet[2]] <= self.entities_max):
                triple_list_filter_entities.append(triplet)
        return triple_list_filter_entities
```

结果介绍

> 在保证子图完整度的前提下，考虑到内存的影响，我们做了两跳子图以及两次过滤。
>
> 其中第二跳子图基于第一跳子图过滤后生成的实体。
>
> 第一次过滤的参数为实体数最小 40，最大 20000，关系数最小 50
>
> 第二次过滤的参数为实体数最小 20，最大 20000，关系数最小 50

结果如下：

	第一跳子图	第一条子图过滤	第二跳子图	第二次子图过滤
三元组数	502128	37981	317217383	277816
实体数	308789	760	50861749	23948
关系数	452	49	1818	62
生成文件类型	.txt.gz	.txt	.txt.gz	.txt
生成文件大小	9.9MB	5.2MB	1.38GB	74MB

Stage2

生成可供操作的 kg_final

通过给定的豆瓣 id 与 freebase id 的映射以及 豆瓣 id 与 kg_final 最终 id 的映射关系，我们可以得到 freebase id 与 kg_final 最终 id 的关系。并对剩余的未编号实体以及关系接下去编号，最终将第一阶段生成的第二跳过滤子图变成用连续数字所代替的子图。

其中编号代码如下（以实体编号为例）：

```
entities2id = {}
num_of_entities = 578
for entity in entities:
    if entity in entity2id.keys():
        entities2id[entity] = entity2id[entity]
    else:
        entities2id[entity] = str(num_of_entities)
        num_of_entities += 1
```

> 最终生成的 kg-final 的三元组、实体、关系数量与第二跳子图过滤后的参数一致。但是大小变为了 8.5 MB，更加便于下文的处理。

处理得到kg_data、kg_dict、relation_dict

将三元组逆向并添加到原三元组中得到kg_data，代码如下(主要调用了pandas库进行实现)：

```
n_relations = max(kg_data['r']) + 1# 原来的relations映射到[0, n_relations)
new_kg = kg_data.copy()
new_kg[['h', 't']] = new_kg[['t', 'h']]
new_kg['r'] = new_kg['r'] + n_relations
self.kg_data = pd.concat([kg_data, new_kg], ignore_index=True)
```

构建kg_dict、relation_dict的代码如下：

```
self.kg_dict = collections.defaultdict(list)
self.relation_dict = collections.defaultdict(list)
# 遍历 DataFrame 的每一行
for _, row in self.kg_data.iterrows():
    head = row['h']
    relation = row['r']
    tail = row['t']
    # 对 self.kg_dict 进行更新
    self.kg_dict[head].append((tail, relation))
    # 对 self.relation_dict 进行更新
    self.relation_dict[relation].append((head, tail))
```

将知识图谱嵌入到模型中，实现TransE算法

这里主要尝试了两种方式：

1. 通过将embedding直接相加得到最终的embedding

```
# calc_cf_loss()函数:
item_pos_cf_embed = item_pos_embed + item_pos_kg_embed
item_neg_cf_embed = item_neg_embed + item_neg_kg_embed

# calc_loss()函数:
item_cf_embed = item_embed + item_kg_embed
```

2. 通过将embedding直接相乘得到最终的embedding

```
# calc_cf_loss()函数:
item_pos_cf_embed = item_pos_embed * item_pos_kg_embed
item_neg_cf_embed = item_neg_embed * item_neg_kg_embed

# calc_loss()函数:
item_cf_embed = item_embed * item_kg_embed
```

结果测试与模型对比

首先我们按照默认参数运行了KG_free，也就是未嵌入知识图谱的MF模型。baseline跑出的结果如下：

Recall@5	NDCG@5	Recall@10	NDCG@10
0.0660	0.3110	0.1094	0.2829

然后我们按照默认参数运行了Embedding_based，也就是嵌入了知识图谱的MF模型，采用的是embedding相乘进行嵌入，测出的结果如下：

Recall@5	NDCG@5	Recall@10	NDCG@10
0.0653	0.3001	0.1105	0.2762

> 可以看到与baseline得到的结果并没有太大差别。这里猜测可能是提取出来的知识图谱没有包含太多让模型可以学习的东西，或者受困于MF模型的结构使得很难对原来结果显著提升，亦或者是因为embedding的处理方式导致结果与baseline几乎一致。

于是我们下面对embedding的处理方式做出了调整，让两个embedding相加然后进行嵌入，测出的结果如下：

Recall@5	NDCG@5	Recall@10	NDCG@10
0.0655	0.3014	0.1074	0.2743

> 改变embedding的处理方式依旧得到了与baseline相近的结果。

然后我们在embedding相乘的基础上调了调参数，首先是修改了 `embed_dim` 、 `relation_dim` ，让其在[16, 24, 32, 48, 64]中取值，并使得其他参数与原来保持一致，测试脚本如下：

```
for embed_dim in 16 24 32 48 64
do
    for relation_dim in  16 24 32 48 64
    do
        python main_Embedding_based.py --seed 2022 \
                                       --use_pretrain 0 \
                                                --pretrain_model_path
'trained_model/Douban/Embedding_based.pth' \
                                       --cf_batch_size 1024 \
                                       --kg_batch_size 2048 \
                                       --test_batch_size 2048 \
                                       --embed_dim $embed_dim \
                                       --relation_dim $relation_dim \
                                       --KG_embedding_type "TransE" \
                                       --kg_l2loss_lambda 1e-4 \
                                       --cf_l2loss_lambda 1e-4 \
                                       --lr 1e-3 \
                                       --n_epoch 1000 \
                                       --stopping_steps 10
    done
done
```

测试结果可视化如下：

NDCG	RECALL
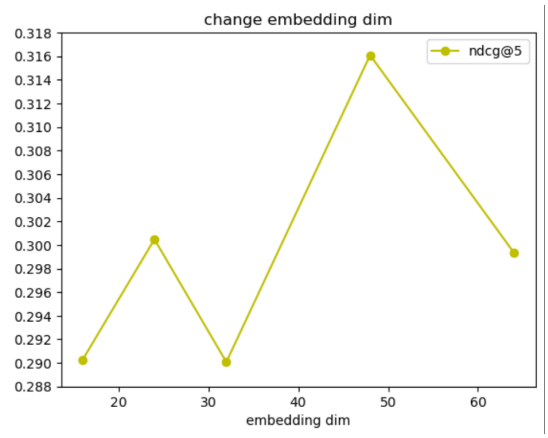	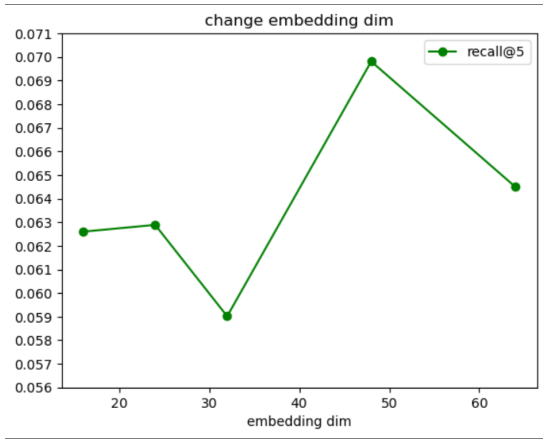
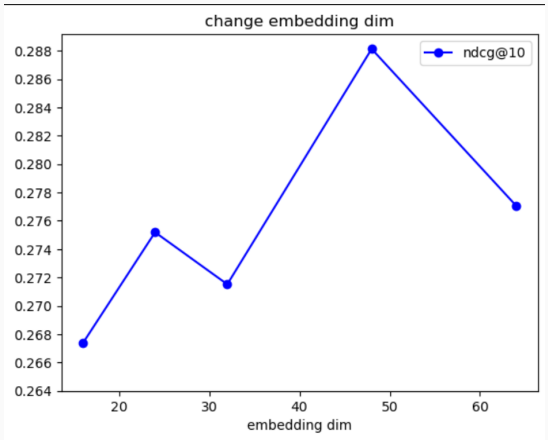	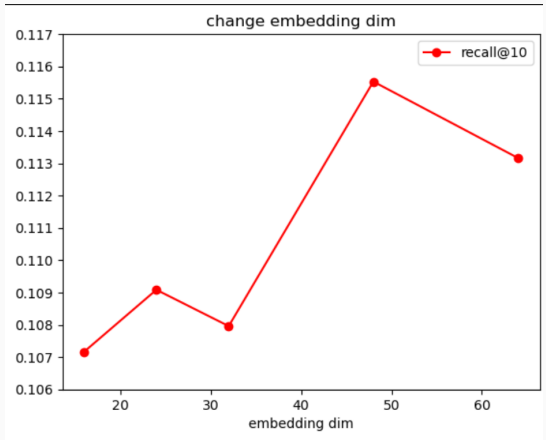

> 通过上图结果可以看出：当 embed_dim 、 relation_dim 均调成48的时候可以取得不错的效果，超过了baseline。

最后我们在embedding相乘的基础上调了 lr 、 kg_l2loss_lambda 、 cf_l2loss_lambda 三个参数，测试脚本如下：

```
for lr in 1e-2 1e-4 1e-3
do
    for l2 in 1e-4 1e-5 1e-3 5e-5 2e-4
    do
        python main_Embedding_based.py --seed 2022 \
                                       --use_pretrain 0 \
                                                --pretrain_model_path
'trained_model/Douban/Embedding_based.pth' \
                                       --cf_batch_size 1024 \
                                      --kg_batch_size 2048 \
                                      --test_batch_size 2048 \
                                      --embed_dim 32 \
                                       --relation_dim 32 \
                                       --KG_embedding_type "TransE" \
                                       --kg_l2loss_lambda $l2 \
                                      --cf_l2loss_lambda $l2 \
                                      --lr $lr \
                                      --n_epoch 1000 \
                                      --stopping_steps 10
    done
done
```

测试结果可视化如下：

NDCG	RECALL
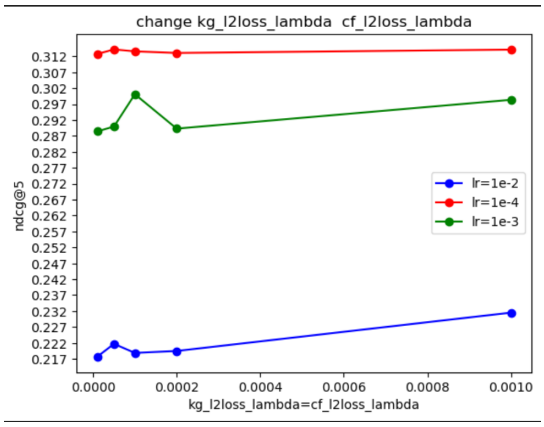	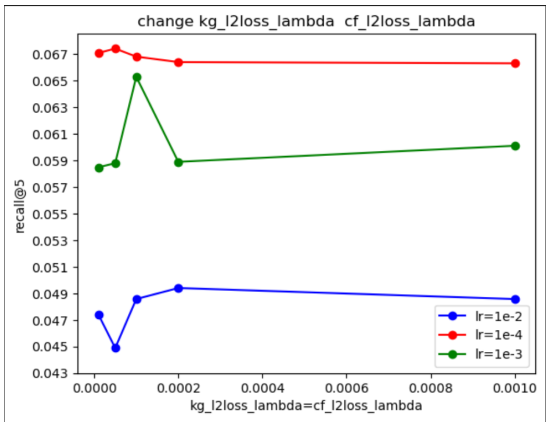
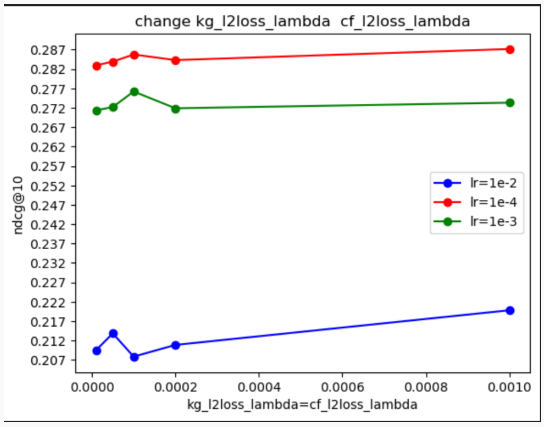	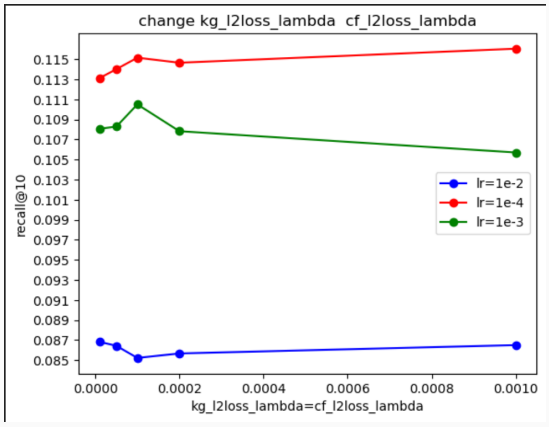

> 通过上图结果可以看出：`lr` 在1e-4效果最好1e-3次之1e-2效果最差；`kg_l2loss_lambda`、`cf_l2loss_lambda` 的改变对效果的影响并不是很大。